

EmploiMatch Congo

Système intelligent d'appariement entre demandeurs d'emploi et offres d'emploi

Rapport technique. Hackathon IndabaX Congo 2026 x ACPE. Glenn Jose MATONDO, juillet 2026.

1. Le problème de départ

L'ACPE reçoit chaque année des milliers d'offres d'emploi et des dizaines de milliers d'inscriptions de demandeurs. La mise en relation entre les deux se fait encore largement à la main: un conseiller lit les dossiers, se souvient des offres ouvertes et fait le rapprochement lui-même. Ce travail prend du temps et laisse forcément passer de bonnes correspondances.

Nous avons donc construit un moteur d'appariement automatique. Pour chaque demandeur, il calcule un score de compatibilité avec chacune des offres disponibles, classe les meilleures et justifie son choix en montrant les compétences partagées et celles qui manquent. Un tableau de bord donne aux conseillers une vue d'ensemble du marché.

2. Données et préparation

2.1 Ce que contiennent les fichiers fournis

Nous avons travaillé sur quatre fichiers du dossier officiel. Offres ACPE 2535 offres avec leur intitulé, le secteur, l'entreprise, le lieu et le type de contrat. Offres_ACPE_Extensions.xlsx décrit plus finement 143 de ces offres: description du poste, profil recherché, parfois une liste de compétences. Demandeurs.xls contient 41298 profils. Le dernier fichier, Appariement_Demandeurs_Offres.xlsx, sert de vérité terrain: chaque demandeur y est associé aux trois offres jugées pertinentes pour lui.

2.2 Nettoyage des offres (src/prepare_data.py)

- Quatre offres apparaissaient en double, nous les avons retirées. Il reste 2 531 offres, fusionnées avec leurs extensions en une table unique.
- Le champ Lieu mélangeait majuscules, espaces parasites et noms de départements (Brazzaville, Nkayi, Bouenza). Tout a été ramené à une forme unique.
- Quand une offre décrit son profil en texte libre, nous en extrayons le diplôme et l'expérience exigés par expressions régulières: « Bac+2/3 » devient BAC+2, « 2 à 5 ans » devient 2 ans.
- Nous avons constitué un référentiel de 137 compétences réparties sur 12 secteurs du marché congolais, puis cherché ces compétences dans le texte de chaque offre, sans tenir compte des accents ni de la casse. 1 350 offres en ressortent avec des compétences structurées.

2.3 Conversion des profils demandeurs

Les profils réels ne donnent ni la ville de résidence ni les années d'expérience. Nous avons récupéré le département en décodant le préfixe du matricule (PPBZV pour Brazzaville, PPPNR pour Pointe-Noire, et ainsi de suite pour les douze départements) et projeté les niveaux d'études déclarés sur une échelle ordonnée, « Bac +3 » devenant Licence par exemple. Un texte de profil est ensuite composé à partir du métier visé, de la qualification, de la filière, des secteurs et du diplôme, en ignorant les champs « Non déclaré ». Après suppression de 13 doublons, il reste 41 285 profils. L'extraction par référentiel trouve des compétences pour 29 620 d'entre eux, soit 72 %.

3. Le moteur d'appariement

Le score de compatibilité additionne quatre signaux pondérés. Nous avons volontairement écarté les approches de type boîte noire: un conseiller doit pouvoir justifier une recommandation devant le demandeur qu'il reçoit.

Composante	Poids	Technique	Ce qu'elle apporte
Compétences	40 %	Couverture des compétences requises de l'offre par le candidat, via le référentiel	Le signal le plus lisible : compétences communes et manquantes affichées
Similarité lexicale	20 %	TF-IDF sublinéaire, unigrammes et bigrammes, sur texte normalisé	Le vocabulaire partagé entre profil et offre
Similarité sémantique	25 %	Embeddings multilingues (Sentence Transformers), en option	Rapproche des formulations différentes de même sens
Critères structurés	15 %	Règles simples : lieu, expérience exigée, diplôme exigé	La faisabilité concrète du placement

Le total est ramené à un pourcentage. Quand une offre ne précise pas l'expérience ou le diplôme, le critère est neutre plutôt que pénalisant: on juge sur ce que l'on sait, pas sur ce qui manque dans la saisie. Et si la bibliothèque d'embeddings n'est pas installée, le moteur se replie de lui-même sur les trois autres signaux. Il tourne donc sur n'importe quelle machine, sans GPU.

Nous livrons en réalité deux jeux de poids. Le profil « conseiller », celui du tableau ci-dessus, privilégie la lisibilité dans l'application. Le profil « classement » sert à produire les recommandations officielles: nous l'avons calibré sur un échantillon de 4 000 demandeurs tirés au hasard, en comparant plusieurs configurations contre la vérité terrain. La similarité textuelle en version sublinéaire s'est imposée nettement, avec un Recall@10 de 0,80 sur l'échantillon là où notre pondération initiale plafonnait à 0,47. Ce résultat en dit long sur les données elles-mêmes: la vérité terrain de l'ACPE semble construite sur la proximité des textes.

Pourquoi pas d'apprentissage supervisé ? Avec trois offres pertinentes par demandeur et aucun historique de recrutement, un modèle entraîné aurait surtout appris par cœur. Les poids pourront être appris plus tard, quand l'agence aura accumulé de vraies données de placement.

4. Recommandations et évaluation

4.1 Production des Top-K (src/recommend.py)

Le script produit les classements de tous les demandeurs en une passe vectorisée: matrices creuses scikit-learn, algèbre NumPy, traitement par blocs de 2 000. Les 41 285 demandeurs sont scorés contre les 2 531 offres en 36 secondes environ, sur un ordinateur portable ordinaire. La sortie respecte le format demandé par le guide (candidate_id, rank, job_id, score), pour K = 5 et K = 10.

4.2 Résultats mesurés (src/evaluate.py)

Nous avons d'abord validé le script d'évaluation sur des cas construits à la main, dont les valeurs se vérifient de tête: deux offres pertinentes placées aux rangs 1 et 3 doivent donner exactement P@5 = 0,40 et R@5 = 0,667, et c'est ce qu'il renvoie. Les métriques ont ensuite été calculées sur la totalité des demandeurs, contre le fichier d'appariement de référence :

Métrique	@5	@10
Précision (maximum théorique : 0,60 @5 et 0,30 @10)	0,366	0,230
Recall	0,610	0,768
NDCG	0,597	0,669

Autrement dit, un peu plus des trois quarts des offres retenues par l'ACPE se retrouvent dans notre Top-10, et 61 % dès le Top-5.

4.3 Ce que ça donne au cas par cas

Les classements restent lisibles individuellement. Un technicien de maintenance industrielle basé à Pointe-Noire, avec de l'électromécanique et une habilitation HSE, obtient en tête Électromécanicien, Chargé de maintenance et Technicien HSE, tous à Pointe-Noire. Une caissière de Brazzaville obtient d'abord Personnel de vente et de service client, puis Hôte de caisse. Dans les deux cas, l'application montre quelles compétences ont pesé dans le score.

5. Le prototype

L'application Streamlit est en français et déployée en ligne. Le premier onglet, « Je cherche un emploi », accepte un CV en texte libre: les compétences reconnues s'affichent, puis les offres classées avec leurs sous-scores et leurs compétences manquantes. Le deuxième, « Je recrute », classe les candidats pour une offre donnée et accepte aussi une requête en langage naturel, du type « je cherche un candidat en comptabilité ». Le troisième est le tableau de bord des conseillers, avec les indicateurs demandés par le guide : volumes, secteurs, métiers les plus recherchés, taux moyen de compatibilité, répartition géographique et statistiques des recommandations générées.

Les deux défis bonus sont couverts: la recherche en langage naturel fonctionne dans les deux sens (offres comme candidats), et chaque recommandation affiche les compétences que le candidat devrait acquérir, ce qui peut servir à orienter les formations.

6. Limites et suite

La principale limite vient des données. Les profils demandeurs ne contiennent ni l'expérience ni la ville précise, deux champs qui renforceraient les critères structurés. Côté offres, seules 143 sur 2 531 ont une vraie description. Enrichir la saisie à la source améliorerait directement la qualité de l'appariement, sans toucher au code.

Pour la suite, nous voyons quatre chantiers : apprendre les poids du score à partir des placements réussis, lire les CV PDF (avec OCR, car beaucoup de CV en circulation sont des scans), prendre en compte le lingala et le kituba, et exposer le moteur en API REST pour l'intégrer au système d'information de l'agence.

7. Conclusion

Le prototype couvre le cahier des charges du hackathon, bonus compris, et fonctionne de bout en bout sur les données réelles de l'agence. Il ne dépend d'aucune donnée codée en dur: pour le passer en production, on remplace les fichiers d'entrée et on relance les scripts. Le reste est une affaire d'intégration au système existant de l'ACPE.